


영상 특징과 치수 정보를 활용한 단안 팔레트 자세 추정용 국소 키포인트 보정

저자 정보 확정 전

Abstract—팔레트 자세 추정은 제조·물류 환경에서 화물에 접근하고 포크를 정렬하는 데 필요한 위치와 방향 정보를 제공한다. 그러나 컬러 영상에서 팔레트를 올바르게 검출하더라도 코너 위치와 대응의 오차가 남아 자세 추정의 정확도를 제한할 수 있다. 본 연구는 등록 치수를 사용할 수 있고 초기 팔레트 코너가 이미 산출된 조건에서, 영상 특징과 치수에 따른 국소 키포인트 보정을 평가한다. 검출 실패 복구나 독립 계측 정확도는 평가 범위에 포함하지 않는다. 영상 기반 초기 추정기의 가중치를 고정된 상태에서 보정기를 학습하며, 초기 코너 주변의 다중 해상도 특징과 치수로 이동 후보를 점수화한 뒤 후보 변위의 확률 가중평균으로 좌표를 수정한다. 학습에는 객체의 회전 동등성을 고려한 코너 대응을 사용하고, 보정 전후의 자세 계산에는 동일한 카메라 정보와 치수를 적용한다. 반복 개발에 사용한 직사각형 실사 영상 319장에서 YOLO의 코너 오차 중앙값은 6.72에서 5.78픽셀로, 기하 재구성 참조에 대한 위치·회전 오차 중앙값은 각각 7.90에서 7.07cm, 2.54에서 2.07도로 감소했다. DOPE와 ResNet-18에도 동일한 구성의 보정기를 각각 학습·적용해 코너 오차 중앙값의 감소를 확인했으며, 별도 정사각형 영상 119장에서도 세 기반의 2차원 보정 효과가 관찰됐다. 다만 큰 오류의 변화와 회전 대응 감독의 추가 이득은 일관되지 않았으며, 결과는 평가한 영상과 참조의 범위에서 국소 보정의 효과를 보여준다.

치수 입력의 추가 효과는 작고 대형 감독의 변화는 혼합되어 전체 보정의 이득을 두 요소 중 하나의 효과로 설명하지 않는다. PoseFix 방식은 더 낮은 중앙 오차를, N3는 더 낮은 코너 P90을 보였으며, 같은 장치·실행 경계의 시간과 함께 방법 전체의 손익을 보고한다.

Index Terms—단안 비전, 물리적 치수, 영상 특징, 키포인트 보정, 팔레트 자세 추정.



I. 서론

팔레트의 위치와 방향을 인지하는 능력은 제조·물류 현장에서 화물에 접근하고 포크를 정렬하여 상·하차를 수행하는 데 필요하다. 영상 기반 포크 안내 [1], RGB-D 카메라를 이용한 인식·위치 추정 [2], 반자동 픽업 지원 [3] 등은 이 인지 정보를 화물 취급에 연결해 왔다. 자율 화물 취급의 다양한 센서·제어 구성을 정리한 연구 [4]에서도 인지와 작업 실행의 연계가 중요한 문제로 다뤄진다.

단안 컬러 영상으로 팔레트를 검출하는 것과 정확한 자세를 얻는 것은 같지 않다. 외형·시점·조명·가림 변화는 코너의 위치와 대응을 불확실하게 만들고, 검출이 성공한 경우에도 남은 위치 오차가 최종 자세의 정확도를 제한할 수 있다. 팔레트 앞면의 표현을 이용하는 접근 [5], 가림에 대응하는 접근 [6], 합성 자료에서 기하 단서를 학습하는 접근 [7]은 서로 다른 관측·표현 조건에서 이 문제를 다룬다. 본 연구의 대상은 물체 검출 자체의 실패보다, 이미 얻은 코너를 추가 정보로 수정할 수 있는 범위이다.

인지 정확도를 높이는 방법에는 영상 적응, 초기 추정기의 추가 학습, 추정 이후의 보정이 있다. 이들은 사용하는 감독과 바꾸는 계산 단계가 다르다. 영상 적응과 다단계 자세 보정을 결합한 팔레트 연구 [8]가 존재하므로 후처리의 존재 자체를 새로움으로 삼을 수는 없다. 본 연구는 기존 추정기를 유지하면서 그 내부 영상 특징과 알려진 치수를 함께 사용해 코너를 국소적으로 보정하는 경우를 분리하여 평가한다. 초기

추정기 업데이트는 대표적인 대안으로 비교하되, 자기학습의 모든 성립 조건을 밝히는 것을 연구 범위로 삼지 않는다.

제안 보정기는 초기 코너 주변의 다중 해상도 특징을 읽고, 물리적 치수에서 얻은 정보로 후보 이동의 점수를 조정한다. 점수 분포의 기댓값으로 좌표를 수정하고 원본 영상 좌표에서 이동량을 제한한다. 코너 이외의 객체 선택·박스·검출 점수·중심점은 유지하며, 보정 전후의 자세 계산에 같은 치수와 카메라 정보를 사용한다. 치수 입력은 코너가 주어진 직육면체의 투영을 반드시 만족하도록 강제하는 제약이 아니라, 후보를 평가하는 학습 신호이다.

검증은 세 질문에 대응한다. 첫째, 기존 추정기에 보정을 더하면 코너와 최종 위치·회전이 함께 개선되는가. 둘째, 영상 기반 국소 보정에 치수와 회전 대응 감독을 추가한 효과가 각각 존재하는가. 셋째, 동일 보정 절차를 서로 다른 추정기에 학습·적용했을 때 효과와 실패 양상이 어떻게 달라지는가. 이를 위해 세 기반 추정기의 보정 전후 비교, 구성 요소 절제, 다른 보정 방법과의 비교, 형상·재질·가림별 분석을 수행한다. 결과는 개선의 중심부뿐 아니라 큰 오류, 손상, 실패율과 추가 계산 비용을 함께 보고한다.

이 연구의 센서 처리 기여는 동결 RGB 추정기에 대한 제한된 코너 정제와 그 최종 자세 전달 효과이다. 319장 개발 자료에서 관측한 개선을 새로운 미사용 환경이나 실제 포크 삽입 성공으로 확대하지 않는다. 작은 추가 이득의 원인을 모델 용량 부족으로 전제하지 않고, 후보에서의 선택 가능성, 실제 선택·학습, 독립 측정의 충분성을 별개 질문으로 둔다.

II. 관련 연구

A. 팔레트 인지·위치 추정과 취급 응용

팔레트 인지 연구에서 사용되는 입력은 컬러 영상, 깊이 영상, 점군 및 거리 센서 등으로 다양하다. RGB-D 기반 팔레트 연구는 깊이 정보를 이용한 템플릿 기반 인식과 위치 추정을 다룬다 [2]. 3차원 카메라 기반 연구는 3차원 카메라를 이용한 위치 추정을 다루며 [9], 창고 팔레트의 구조와 템플릿을 활용하는 RGB-D 방법 [10], 능동 양안 점군의 특징과 정합을 이용하는 방법 [11], 깊이 카메라의 검출 영역과 점군 처리를 결합하는 방법 [12]도 제안되었다. 이 연구들은 깊이 관측을 이용한다는 점에서 현재의 단안 영상 보정과 사용 정보가 다르다. 2차원 거리 자료를 이용한 검출·위치 추정·추적 [13] 역시 RGB 국소 특징과 다른 센서 입력을 사용한다.

학습 기반 팔레트 위치 추정에서도 출력의 의미는 동일하지 않다. RGB 영상과 깊이 데이터를 결합한 검출·위치 추정 [14] 및 여러 깊이 기반 인지 모델의 비교 [15]는 센서 처리 경로 전체를 다룬다. 다중 작업 학습 연구는 영상에서 각도와 거리의 범주를 함께 예측하는 다중 작업 구성을 제안한다 [16]. 구성요소 분할을 통한 위치 추정 [17]과 위성항법 및 비전을 결합한 위치·회전 추정 [18]은 각각 물체 표현과 좌표 정보의 다른 선택을 보여준다. 범주 분류 정확도, 거리 오차 및 전체 6D 자세 오차를 하나의 성능 순위로 해석하지 않는 이유가 여기에 있다.

팔레트의 인지 결과를 실제 취급으로 연결하는 연구에는 야외 팔레트 handling [19], RGB-D 기반 포크 삽입 [20], 다중 카메라를 이용한 적층 [21], 팔레트 트럭의 검출·도킹 [22], 학습 기반 화물 이송 시스템 [23], 영상 측정 기반 접근·삽입 [24]이 있다. 본 연구는 이러한 전체 제어 절차를 새로 제안하는 대신, 제어에 공급되는 인지 결과의 보정에 초점을 둔다. 실제 장비에서 수집된 영상을 이용한다는 사실과 제안 보정으로 장비를 제어했다는 주장은 구분한다.

B. 합성 학습과 단안 팔레트 자세 추정

Euro 팔레트 합성 학습 연구는 합성 영상을 이용해 DOPE 계열 추정기를 학습하고 RGB 카메라 기반 팔레트 자세 추정을 평가하였다 [25]. 이 연구의 실제 센서 평가는 웹캠과 팔레트의 광학 모션 캡처 참조를 사용한다. 현재 원고의 같은 2D 레이블에서 재구성한 PnP 참조는 이러한 독립 계측과 구분한다. 팔레트 합성 위치 추정 연구는 합성 데이터와 팔레트 면의 기하 정보를 사용하는 접근이다 [26]. 따라서 합성 영상으로 학습하거나 코너와 알려진 기하를 이용해 자세를 구하는 전체 구성 자체는 선행연구와 구별되는 발명이 아니다.

관측 외형과 기하 표현을 분리하는 연구도 있다. 합성 학습과 stereo depth의 표면 기하를 이용하는 팔레트 인지 [27], disparity 및 점·선분 투표를 이용하는 연구 [7]는 가림과 외형 변화를 다룬다. 앞면 기반 자세 추정은 앞면 관측과 신경망·커널 회귀를 이용해 적재물 외형 변화에 대응한다 [5]. 단안 거리 기반 자세 추정은 단안으로 예측한 거리 정보와 기하 단서를 활용한다 [28]. 물리적 깊이 센서의 관측, 단안으로 학습한 depth, 사전에 제공한 치수는 서로 다른 정보이므로 이를 명시한 비교가 필요하다.

C. 구조 정보를 이용한 키폰트 추정

팔레트의 규칙적인 구조를 이용하는 접근은 이미 연구되어 왔다. 전이학습 기반 키폰트 연구는 개선된 YOLOv8s-pose 계열과 E형 단면의 키폰트, 강건한 기하 계산을 결

합한다 [29]. 개선된 인체 자세 모델의 팔레트 적용은 개선된 YOLOv11s-pose와 topology 정보를 결합한 위치 추정이다 [30]. 하이퍼그래프 기반 팔레트 자세 추정은 키폰트의 고차 공간 관계와 구조 사전정보를 활용한다 [31]. 따라서 본 연구의 동기는 기존 연구가 구조를 전혀 사용하지 않는다는 주장에 있지 않다. 이미 학습된 추정기의 결과를 유지하면서, 별도의 국소 보정 단계에서 치수 정보와 대응 규칙을 활용했을 때의 추가 효과를 확인하는 데 있다.

D. 입력 적응, 추정기 업데이트 및 출력 보정

입력 표현을 바꾸는 접근의 예로 CUT는 대응 영상 쌍 없이 패치 수준의 대조 학습을 이용한 영상 변환을 제안한다 [32]. 팔레트 연구에서는 CUT와 CosyPose를 결합한 단단계 보정이 보고되었다 [8]. 이 방법은 영상 적응과 자세 보정을 함께 사용하므로, 합성 학습만으로 목표 영역의 정보를 전혀 보지 않은 설정과 동일하지 않다. 자기지도 pose 적응의 예인 Self6D도 단안 추론과 실사 RGB-D 학습 신호를 구분하여 이해해야 한다 [33]. 이러한 선행의 성공이 현재의 의사 레이블만을 사용하는 자기학습 설정에서도 같은 효과를 보장하지 않는다.

출력 보정에서는 PoseFix가 이미지와 초기 키폰트를 입력받아 정제된 자세를 산출한다 [34]. DeepIM은 초기 자세로 렌더링한 영상과 관측 영상을 정합하여 자세를 반복적으로 갱신하며 [35], CosyPose는 단일 시점 자세 가설과 객체 대칭을 다루고 다중 시점 장면을 정제한다 [36]. 본 연구는 이들과 달리 기존 추정기의 내부 특징을 읽고 코너 주변의 제한된 범위 분포를 계산한다. 이는 전체 RGB 특징을 별도로 추출하거나 물체를 반복 렌더링하는 구성과 비교할 수 있지만, 내부 특징에 접근해야 하므로 모든 추정기에 같은 가중치를 그대로 적용할 수 있다고 주장하지 않는다. 특히 PoseFix의 원래 설정은 다른 추정기의 내부 코드나 특징을 필요로 하지 않는 반면, 본 방법은 기반별 특징·좌표 연결부와 보정 헤드 학습을 요구한다. 따라서 본문의 검증 대상은 동일 보정 절차의 여러 추정기 적응성이다.

본포에서 좌표를 계산하는 기대값 연산은 Integral Human Pose Regression 등의 선행에서 다루어졌다 [37]. BB8은 코너 투영으로 자세를 표현할 때의 대칭 모호성을 다루며, 관측 영상과 현재 자세의 렌더링을 비교하여 2차원 코너 투영을 반복 보정하는 선택적 단계도 제안한다 [38]. DeepIM의 객체 중심 회전과 상대 이동 표현은 렌더링 정합을 위한 것이며, 본문의 N3나 보충자료의 자세 결합 변위 후보가 DeepIM을 재현한 것은 아니다. 본 연구는 기대값 연산이나 대칭 고려 자체를 새롭게 제안하는 것이 아니라, 팔레트 코너 보정의 정보·감독·평가 조건을 묶어 추가 효과를 검토한다. 표 I는 비교에 필요한 정보와 초기화 조건을 정리한다. 깊이 센서·렌더링·독립 초기 자세의 사용 여부가 다르다면 보고된 정확도 수치를 현재 실험의 직접 기준선으로 옮기지 않는다.

III. 문제 정의와 제안 방법

A. 시스템 입력과 기반 추정기의 역할

전체 시스템은 RGB(Red, Green, Blue) 컬러 영상 I , 카메라 내부파라미터 $\mathbf{K}$, 팔레트의 가로·깊이·높이 $\mathbf{d} = (W, D, H)$ 를 입력으로 사용한다. 자세는 카메라에 대한 회전 $\mathbf{R} \in SO(3)$ 과 위치 $\mathbf{t} \in \mathbb{R}^3$ 으로 정의한다. 초기 추정기는 영상에서 코너와 특징을 추출하고, 제안 보정 신경망은 이 결과와 물리적 치수를 함께 입력받아 코너를 수정한다. 같은 치수는 최종 자세 계산에도 사용된다.

TABLE I

주요 팔레트 선행과 본 연구의 입력·수정 대상. 센서와 초기화가 다른 보고 수치를 직접 순위화하지 않는다.

연구	핵심 정보	접근과 본 연구의 차이
Euro pallet 합성 학습 [25]; Synthetic localisation [26]	합성 RGB, 코너와 객체 기하	초기 검출·자세 추정을 학습; 본 연구는 얻어진 초기 코너 이후의 추가 수정을 평가
Front Face Shot [5]; Geometric cues [7]	앞면 표현 또는 양안 시차·점·선본	관측 표현·센서 증거를 바꾸는 접근과 후단 코너 보정을 구분
개선 pose 추정기 [29], [30]; Hyper-graph [31]	단면 키포인트, 구조·고차 관계	초기 특징·키포인트 추정기를 개선; 물체 구조 활용 자체는 이미 알려진 원리
Occlusion-Robust [6]; Monocular Metric Depth [28]	RGB-D 또는 단안 추정 깊이	관측 깊이·추정 깊이·등록 치수는 다른 정보
Multi-Stage Domain-Adapted [8]	영상 적응, 초기 자세, 렌더링 기반 보정	실제 자료 보정 평가의 참조 자세에 잡음을 더한 초기화와, 본 연구의 추정기 실제 출력은 다름
제안 방법	초기 코너, 내부 영상 특징, 등록 치수	제한된 2D 코너 이동을 학습하고 같은 자세 계산으로 전후 효과를 평가

기반 추정기를 f_{θ_β} , 기반별 특징·출력 연결부를 h_β 로 나타낸다. 연결부는 각 추정기의 출력을 초기 코너 8점·중심점 1점, 유효성 마스크, 박스와 두 수준의 특징으로 변환한다. 보정기를 학습하는 동안 초기 추정기의 가중치는 고정한다. 본문의 모든 Base는 제공된 치수 숫자를 초기 코너 산출에 직접 입력하지 않는 RGB 모델이며, 합성 감독으로 학습한 보정기가 치수를 추가 활용한다. 별도로 존재하는 ResNet 직접 치수 입력 FULL 모델은 이 연구의 Base가 아니다.

YOLO는 검출기 고유의 박스와 점수를 사용한다. DOPE 연결부는 유효 예측 코너의 범위에서 박스를 만들고 코너 확률맵의 최대값을 점수로 사용한다. 원래 DOPE의 affinity 기반 다중 객체 연결과 다른 디코딩 경로이므로, 이 점수를 YOLO 검출 신뢰도와 동등하게 취급하지 않는다. ResNet-18 몸체는 잔차 신경망 원전 [39]에, 세 개의 256채널 역합성곱과 마지막 9채널 확률맵 헤드는 Simple Baselines for Human Pose Estimation and Tracking [40]의 구조에 근거한다. 전체 영상·팔레트 9점·분포 기댓값 디코더는 이 저장소의 변형이며 원 인체 벤치마크 재현이 아니다. 이 기반은 치수 문맥을 0으로 고정하여 합성 자료로 10 epoch 학습한 CONSTANT 기반이다. 그 고정 특징 변환을 마지막 합성곱에 합쳐 RGB만 입력받게 하며, 공간 확률분포의 기댓값으로 초기 좌표를 계산한다. CONSTANT는 치수 조건이 고정되었다는 뜻으로, 이미지에 따른 좌표 출력이 상수라는 뜻이 아니다. 기반별 전처리·디코더·특징 연결의 상세는 보충자료에 정리한다.

보정 대상은 코너 $k = 0, \dots, 7$ 이다. 객체 선택, 박스, 점수, 후보 순서, 중심점 $k = 8$ 및 결측 마스크는 변경하지 않는다. 이 출력 보존은 코너나 자세 정확도의 보존을 보장하지 않는다. 치수는 등록된 객체 정보에서 제공하며 영상으로 임의 팔레트의 규격을 추정하지 않는다.

B. 좌표계와 기반별 특징 연결부

원본 영상 좌표를 $\mathbf{u}^I$, 기반 β 의 네트워크 입력 좌표를 $\mathbf{u}^{N,\beta}$ 로 구분한다. 크기 변환과 패딩의 관계는 다음과 같다.

$$\mathbf{u}^{N,\beta} = A_\beta \mathbf{u}^I + \mathbf{a}_\beta, \quad A_\beta = \text{diag}(g_{x,\beta}, g_{y,\beta}). \quad (1)$$

여기서 $\mathbf{a}_\beta$ 는 패딩 등에 의한 평행이동이다. 이동 벡터의 역변환에는 평행이동이 포함되지 않는다. 이미지, 코너, 박스와 특징 표본 위치는 같은 전처리 기록을 사용한다. YOLO에서 하나의 크기 비율을 쓰는 경우와, 실제 가로·세로 크기로 축별 비율을 계산하는 DOPE·ResNet 연결을 구분한다.

두 특징을 $F_\beta^{(1)}, F_\beta^{(2)}$ 로 쓴다. 기반마다 채널 수와 특징 간격이 달라 연결층을 별도로 학습한다. 후보 구성·치수 표현·

분포 계산·이동 상한은 공통이며, 특징 셀 중심에 따른 보간 규칙과 원본 좌표 변환을 기반별로 적용한다.

C. 국소 후보와 시각적 점수

이 절의 박스와 좌표는 네트워크 입력 기준이다. 예측 박스의 대각선을 ℓ_β^N 라 하면, 각 코너의 이동 후보는 13개 방향과 17개 반경으로 구성된다. 정규화 변위 $\mathbf{v}_j$ 의 최대 노름은 0.08이고, 영벡터 후보를 추가해 총 $J = 222$ 개를 사용한다.

$$\mathbf{u}_{kj}^{N,\text{cand}} = \mathbf{u}_k^{N,\beta} + \ell_\beta^N \mathbf{v}_j, \quad \mathbf{v}_J = \mathbf{0}. \quad (2)$$

221개 이동 후보 주변의 4×8 격자에서 두 수준의 특징을 보간하고 결합한다. 학습 가능한 1×1 채널 변환과 공유 패치 인코더를 거친 평균·최대 집계에 코너 역할, 박스 내 위치 및 후보 이동 정보를 결합하여 후보 점수를 얻는다. 무이동 후보는 동일한 패치를 하나 더 추출하는 대신, 후보 특징의 집계와 코너 맥락을 읽는 별도 점수 분기를 사용한다. 이들을 합친 시각 점수를 z_{kj}^{vis} 로 표시한다.

D. 치수 정보에 의한 후보 점수 조정

미터 단위의 치수에서 다음 5차원 특징을 구성한다. 로그 길이는 1m를 기준으로 한 수치이며, 표준화의 평균·표준편차는 학습 자료에서 고정한다.


$$\mathbf{c}(\mathbf{d}) = \left[\log W, \log D, \log H, \log \frac{W}{D}, \log \frac{H}{\sqrt{WD}} \right]. \quad (3)$$

치수 인코더는 5차원 입력을 16차원으로 변환한다. 여기에 코너 역할 8차원, 정규화 후보 변위 2차원, 무이동 표시 1차원을 결합해 27차원을 구성하고, 작은 다층 신경망으로 모든 222개 후보의 치수 점수를 계산한다.

$$z_{kj} = z_{kj}^{\text{vis}} + z_{kj}^{\text{dim}}. \quad (4)$$

치수 점수 분기의 마지막 층은 영으로 초기화한다. 치수는 후보 점수를 조건화하며, 후보의 기하 위치를 치수로 직접 이동시키거나 가려진 코너를 해석적으로 복원하는 입력이 아니다. 추론 시 대칭 종류 코드를 별도로 입력하지 않는다. 3차원 치수와 영상상의 중형비는 같은 값이 아니며, 시점·회전·거리의 영향으로 정사각형 물체도 영상에서는 다른 사각형으로 보일 수 있다. 따라서 치수를 이용해 영상의 코너를 정사각형으로 강제하지 않는다.

(a) 전체 입력: RGB 영상 + 물리적 치수 + 카메라 정보



(b) 학습: 초기 추정기는 고정, 연결 학습층과 보정기를 갱신




Fig. 1. 제안 시스템의 입력과 보정 전후 경로. 초기 RGB 추정기의 동일 출력에서 출발하며 제안 보정기는 영상 특징·초기 코너·물리적 치수를 함께 사용한다. Base와 보정 후 경로의 자세 계산에는 같은 카메라 정보와 치수가 제공된다. 실선은 추론, 점선은 합성 정답에 의한 보정기 학습이다.

(a) 기반별 연결과 시각 증거: 221개 이동 후보 + 별도의 무이동 점수




Fig. 2. 국소 보정 신경망. 두 수준의 영상 특징으로 얻은 시각 점수와 치수 점수를 합하고, 이동 후보의 확률 가중평균을 원본 좌표로 복원한다. 무이동 후보의 시각 점수는 별도 집계 분기를 사용한다. 후보 점수 조정은 치수에 따른 기하 형상 강제와 다르다.

E. 분포 출력과 원본 좌표의 이동 제한

추론에서는 온도 $\tau > 0$ 를 적용한 분포의 기댓값으로 네트워크 좌표 이동을 계산한다.

$$p_{kj}^{(\tau)} = \frac{\exp(z_{kj}/\tau)}{\sum_{l=1}^J \exp(z_{kl}/\tau)}, \quad (5)$$

$$\delta_k^{N,\beta} = \lambda \ell_\beta^N \sum_{j=1}^J p_{kj}^{(\tau)} \mathbf{v}_j. \quad (6)$$

기댓값으로 좌표를 얻는 일반 원리는 Integral Human Pose Regression [37]과 관련되며, 여기서는 국소 변위 후보에 사용한다. 원본 좌표의 이동 벡터와 제한은 다음처럼 명시한다.

$$\delta_k^I = A_\beta^{-1} \delta_k^{N,\beta}, \quad (7)$$

$$\tilde{\delta}_k^I = \delta_k^I \min\left(1, \frac{\alpha D_I}{\|\delta_k^I\|_2}\right), \quad (8)$$

$$\mathbf{u}_k^{I'} = \mathbf{u}_k^I + \tilde{\delta}_k^I. \quad (9)$$

D_I 는 원본 영상의 대각선, $\lambda = 1$, $\alpha = 0.01$ 이다. 이동이 영벡터이면 배율은 1이다. 등방 크기 변환인 $A_\beta = gI_2$ 에서는 네트워크 좌표의 상한 $\alpha D_I g$ 를 적용한 뒤 g 로 나누는 것과 같다.

유효 초기점이나 특징 지원이 없는 코너는 새 좌표로 완성하지 않고 그대로 유지한다. 이동 제한은 큰 수정을 막지만 작은 잘못된 수정까지 방지하지 않는다.

F. 객체 전체의 회전 대응과 학습 손실

객체 구조와 주석 규칙에서 허용하는 전체 코너 순열 집합 Π_i 를 사용한다. $0^\circ \cdot 180^\circ$ 의 두 대응은 180도 회전 동등성 (C_2), $0^\circ \cdot 90^\circ \cdot 180^\circ \cdot 270^\circ$ 의 네 대응은 90도 간격 회전 동등성 (C_4)이다. 데이터 집단은 직사각형·정사각형으로 구분하되, 지지면의 형상만으로 객체나 포크 작업의 회전 동등성을 자동 결정하지 않는다. 각 순열은 코너 전체에 일관되게 적용한다.

학습에서는 고정된 초기 예측과 허용된 정답 코너 배열 사이의 평균 정규화 거리가 작은 전체 순열 하나를 선택한다. 코너를 독립적으로 재매칭하지 않고 정답 좌표와 유효성 마스크를 같은 순열로 옮긴다. 결측 예측의 정규화 벌점은 1이며 동물은 원래 대응을 우선한다. 이 단계는 최종 보정 손실에 대한 순열별 최솟값 선택과 다르다.

선택된 정답에서 초기 예측을 뺀 네트워크 좌표 잔차를 $\mathbf{r}_k^{N,\beta}$ 라 하면, 목표 분포는 다음과 같다.

$$q_{kj} = \frac{\exp[-\|\ell_\beta^N \mathbf{v}_j - \mathbf{r}_k^{N,\beta}\|_2^2 / (2\sigma^2)]}{\sum_l \exp[-\|\ell_\beta^N \mathbf{v}_l - \mathbf{r}_k^{N,\beta}\|_2^2 / (2\sigma^2)]}, \quad \sigma = \frac{0.08 \ell_\beta^N}{17}. \quad (10)$$

실제 학습의 예측 분포는 $p^{(1)}$, 즉 온도 1의 softmax이다. m_{ik} 를 해당 영상·코너의 유효 감독 표시, $n_i = \sum_k m_{ik}$ 라 하면 손실은

$$\mathcal{L} = \frac{\sum_i \mathbf{1}[n_i > 0] \frac{1}{\max(1, n_i)} \sum_k m_{ik} [-\sum_j q_{ikj} \log p_{ikj}^{(1)}]}{\max(1, \sum_i \mathbf{1}[n_i > 0])}. \quad (11)$$

학습 후 합성 보정 집합에서 선택하는 추론 온도와 학습 손실을 구분한다. 정답과 정답 기반 순열 선택은 배포 추론에 존재하지 않는다.

G. 동일한 기하 계산을 통한 자세 산출

원래 코너와 보정 코너에는 같은 Perspective-n-Point(PnP) 절차를 적용한다. PnP는 알려진 3차원 점과 영상 대응점, 카메라 내부파라미터로 위치·회전을 구하는 문제이다. 보정 없는 기준선도 같은 치수로 구성한 3차원 코너를 사용한다. 따라서 N3의 치수 효과는 치수를 최초로 알려주는 효과가 아니라, 이미 자세 계산에 제공한 치수를 보정 점수에서도 활용하는 효과이다.

자세 계산은 예측에만 의존하는 가로·깊이 가설 선택, SQPnP [41] 및 비선형 정밀화로 구성된다. 추정 코너가 바

뀌어 선택된 가설이 달라질 수 있으나, 선택 알고리즘과 정보 조건은 고정한다. 유효 코너가 부족하거나 해가 유효하지 않으면 실패로 남긴다. 카메라·치수·객체 축·좌표 복원·실패 처리를 결과에 맞춰 변경하지 않는다.

본 평가의 C_2 와 C_4 는 정준 xyz=[W,H,D]의 수직 Y축을 중심으로 하는 각각 $\{0, \pi\}$ 와 $\{0, \pi/2, \pi, 3\pi/2\}$ 의 허용 회전군이다. 정준 좌표의 해당 수직 축과 camera-facing 코너 순서는 저장소의 고정 축 변환에 따른다. $W = D$ 라는 치수 등식만으로 포크 입구, 적재물, 외관의 90도 동등성을 승인하지 않으며, 데이터의 허용 전체 대응 계약에서 선언한 순열에만 적용한다.

IV. 실험 설정

A. 학습 자료와 평가 집합

추가 보정기에는 합성 코너 감독을 사용한다. 등록된 합성 자료 60,000장은 학습 55,980장, 추론 온도 선택용 calibration 1,004장, selection 1,031장, held-out 1,985장으로 나뉜다. 뒤의 두 분할은 원래 등록된 역할을 보존하되, 본문의 실사 결과나 독립 평가의 근거로 사용하지 않는다. 이 두 분할의 현재 실험 내 추가 사용 이력은 확인이 필요하다. 초기 추정기의 일반 영상 사전학습과 추가 보정기 학습은 구분하며, 전체 시스템의 모든 사전학습이 합성 전용이었다고 가정하지 않는다.

주 실사 집합은 13개 촬영 세션의 직사각형 영상 319장으로, 플라스틱 194장과 목재 125장을 포함한다. 이 집합은 개발과 분석에 반복 사용되었으며 독립 미사용 시험집합이 아니다. 서로 다른 실제 팔레트 개체 수, 프레임 모집·제외의 전체 이력 및 카메라별 적용 범위는 아직 완전하게 확인되지 않았다. 따라서 등록된 영상 집합에서의 효과로 해석하며 실제 운용 빈도에 대한 대표성을 주장하지 않는다.


319장의 가능한 코너 자리는 $319 \times 8 = 2,552$ 개이고, 평가 참조가 있는 코너는 2,499개이다. 참조가 없는 53자리와, 참조는 있지만 YOLO의 조건부 평가에 포함되지 않은 54코너를 구분한다. YOLO의 2D 객체 매칭 영상은 311장, 유효 평가 예측은 2,445코너이다. 전체 YOLO Base와 N3의 자세 산출 및 위치·회전 통계는 319/319장이고, 2D 개선과 6D 손상을 함께 비교하는 공동 분석에는 매칭된 311장을 사용한다. 참조 좌표에는 수동 표시와 기하 보완이 포함되며, 각 생성 경로의 정확한 비율은 현 집합에서 추가 확인이 필요하다.

정사각형 GREEN0918은 등록 치수 [1.1, 1.1, 0.15]m인 팔레트의 119장·한 촬영 세션이다. 동일한 고정 모델에 대해 선언된 수동 코너 602개와 화면 밖 좌표 2개를 제외한 600개 모드를 각각 보고한다. 두 모드는 동일 영상의 참조 포함 규칙만 다르다. 가능한 952자리 중 350자리는 전체 모드에도 참조가 없으며, 이를 예측 실패로 세거나 전부 가려진 코너로 간주하지 않는다. 과거 실사 지도자료와의 개체·촬영·학습 이력 전체 대응은 미확인이므로 미관측 객체 일반화로 부르지 않는다. 독립 표준 자세 참조가 없어 정사각형 위치·회전 정확도는 x으로 남긴다.

B. 사람 입력 등급과 코너 가시성

표 III은 원본 RGB 해시와 frame ID에 연결한 최신 사람 입력 등급의 구성이다. 직사각형 319장은 없음 153장, 중간 92장, 어려움 74장이며 플라스틱은 72/57/65장, 목재는 81/35/9장이다. 정사각형 119도 없음 3장·중간 85장·어려움 31장으로 입력되었다. 이는 등급 입력 완료를 뜻하며 판정 기준의

(a) 객체 구조·주석 규칙에서 허용하는 전체 회전 대응



(b) 학습 전용: 하나의 전체 순열과 마스크를 함께 선택




Fig. 3. 직사각형과 정사각형의 전체 회전 대응 예시 및 학습 경로. a~d는 윗면을 설명하기 위한 표시이다. 초기 예측을 기준으로 하나의 전체 순열을 선택하고 8 코너와 유효성 마스크를 함께 옮긴다. 정사각형의 네 방향 예시는 허용 가능한 대응의 설명이며, 본 합성 학습에 네 방향 대응 표본이 있었다는 뜻이 아니다. 해당 학습 행 수는 0개였다.

TABLE II

학습·평가 자료의 역할과 확인 범위. 실사 집합들은 하나의 독립 시험집합으로 합산하지 않는다.

자료	영상 수	역할
합성 학습	55,980	보정기 합성 감독
합성 calibration	1,004	추론 온도 선택
합성 selection	1,031	등록 분할; 추가 사용 이력 확인 필요
합성 held-out	1,985	등록 분할; 별도 평가 완료를 뜻하지 않음
직사각형 실사	319	13세션; 재사용 개발 평가
플라스틱 / 목재	194 / 125	319장의 하위집단
정사각형 실사	119	1세션; 별도 2D 평가
업데이트 대안	128	공통 비노출 개발 부분집합

합성 네 분할 합계는 60,000장이다. 초기 추정기의 사전학습과 보정기의 추가 학습을 구분한다. 두 128장 집합은 frame ID가 전수 일치하며, 개체 수와 모집·제외 이력은 추가 확인 대상이다.

사람 확인과는 구분된다. 현재 판정 기준은 미확인 상태이므로 외부 가림 검수 완료로 표현하지 않고 보조 사후 분석으로 제시한다.

외부 물체 가림·팔레트 자체 가림·화면 밖 잘림은 서로 다른 속성이다. 최신 사람 입력의 중간·어려움 경계와 이 속성의 포함 여부를 CLI가 추정해 확정하지 않았다. 과거 외부 가림 128장 패널은 기존 29/20/79와 더 오래된 29/21/78 버전 차이를 포함한 원래 출처와 숫자로 별도 보존하며 최신 319장 등급과 같은 계약으로 합치지 않는다. 임의로 개수를 맞추거나 오차에 따라 집단을 재선택하지 않았다.

영상 단위 등급과 코너 단위 가시성도 구분한다. 기존 잠금 71점과 새 입력 3030점을 중복 없이 연결해 직사각형 2499점·정사각형 602점의 총 3101개 참조 코너 상태를 보존하였다. 오차 계산에는 원래 평가 참조 좌표와 같은 전체 객체 대응을 사용하며, 새로운 재클릭이나 PnP 생성점으로 정답 좌표를 교체하지 않았다. 가시성 입력과 좌표의 생성 경로·독립 블라인드 검수 여부는 서로 다른 정보이다. 상세 결과와 한계는

TABLE III

최신 사람 입력 등급(기준 미확인)의 구성.

집단	없음	중간	어려움	미입력	전체
직사각형 / 플라스틱	72	57	65	0	194
직사각형 / 목재	81	35	9	0	125
직사각형 합계	153	92	74	0	319
정사각형 119	3	85	31	0	119

숫자는 실제 입력된 등급의 개수이며 판정 기준 승인과 구분한다. 과거 외부 가림 128장 레이블과 혼합하지 않는다. 과거 정사각형 150장은 별도 7세션 자료로 현 119장 성능 분모에 넣지 않았다.

보충자료에 둔다.

C. 비교 방법과 추가 학습

Base는 같은 기반 추정기의 보정 없는 출력이다. 세 기반은 YOLO, DOPE(Deep Object Pose Estimation) [42], ResNet(Residual Network)-18 몸체 [39]와 Simple Baselines 기반 헤드 [40]를 사용한 팔레트 9점 모델이다. 같은 Base 출력에 N3를 적용한 전후를 비교하며, 특징 연결층과 보정기는 기반별로 학습한다. 이 실험의 목적은 기반끼리의 절대 순위가 아니라 동일 보정 절차의 적용성이다.

구성 요소 비교는 YOLO에서 영상 기반 국소 보정 N0, 회전 대응 감독만 추가한 N1, 치수만 추가한 N2, 둘을 결합한 N3를 사용한다(표 IV). 초기화·표본 순서·추가 학습량을 맞춘 비교이지만 치수 분기의 정보 내용과 추가 파라미터 효과를 완전히 분리하지는 못한다. 기존 독립 실행의 영상 보정 P는 N0와 다른 가중치이며, 전체 방법 비교와 보충자료에서 별도로 구분한다.

N3는 각 기반에서 3개 seed로 학습한다. seed는 초기화와 표본 순서에 사용하는 난수 설정이다. 각 학습은 batch 16·6,000회 업데이트·96,000회 표본 노출이며, AdamW의 기준 학습률 10^{-3} , 가중치 감쇠 10^{-4} , 100회 준비 구간과 코사인 감소, 최종 학습률 0.1배, 기울기 노름 상한 5를 사용한다.

TABLE IV

구성 요소 대조. 모든 경로의 PnP에는 같은 치수를 사용한다.

구성	보정	보정기의 치수 입력	학습 시 회전 대응
Base	없음	-	-
N0	영상 기반 국소 보정	없음	고정 번호
N1	영상 기반 국소 보정	없음	동등성 고려
N2	영상 기반 국소 보정	사용	고정 번호
N3	영상 기반 국소 보정	사용	동등성 고려

N0-N3가 구성 요소 비교이다. 별도 실행의 영상 보정 P를 N0로 재명명하지 않는다.

6,000회째 가중치를 평가한다. 유효 고유 학습 행은 DOPE 44,063개·ResNet 55,806개로, 같은 노출량이 같은 고유 자료 수나 기본 모델까지의 동일 총학습량을 뜻하지 않는다.

학습 손실의 온도는 1이다. 추론 온도는 합성 calibration에서 {0.5, 1, 2, 4} 중 고정 번호 목표의 교차엔트로피로 선택하며 실사 성능으로 재선택하지 않는다. DOPE와 ResNet의 여섯 실행은 모두 온도 1을 선택하였다. 후보 구성과 원본 이동 상한은 평가 전에 고정한다.

전체 방법 비교에는 직접 회귀 D, 선 구조 보정 L, PoseFix 기반 팔레트 보정과 N3를 포함한다. PoseFix 비교 구현은 공식 네트워크를 기준으로 연산을 대조한 PyTorch 팔레트 9점 변형이며 입력·목표 및 일부 수치 설정을 변경하였다. 3개 seed에서 각각 6,000회 업데이트·96,000회 표본 노출의 최종 가중치를 사용한다. 이는 원 논문의 전체 수렴 학습을 재현했다는 뜻은 아니다. 입력·출력·손실·감독 조건의 차이를 가진 전체 방법 비교이며, D/P의 차이도 분포 출력 하나의 효과로 해석하지 않는다. 비교군의 세부 사전학습·설정 선택과 총학습 예산의 완전한 동등성은 미확인 부분으로 남긴다. Base/N3/PoseFix의 배포 비용은 같은 환경·경계의 별도 계측으로 확인한다.

추정기 업데이트의 대안은 별도 플라스틱 128장에 대해 비교한다. 원래 학생·보정 의사 레이블 학생·합성 추가 학습·Base·Base+N3를 모두 같은 영상에서 평가한다. 이 집합은 공통 비노출 조건이 확인된 재사용 개발 부분집합이며 독립 시험은 아니다. frame ID 전수 대조에서 기존 가림 128장과 교집합 128장, 양쪽 차집합 0장으로 확인되었다.

D. 코너 오차, 자세 오차와 실패 분포

코너 정확도는 원본 영상에서 예측 코너와 참조 코너 사이의 유클리드 거리로 평가한다. 회전 동등성을 허용할 때는 하나의 전체 객체 순열을 적용하고 점별 자유 최근접 매칭은 하지 않는다. 코너 오차 중앙값·P90(px)는 객체 매칭을 통과한 유효 예측 코너에 대한 조건부 통계이다. P90은 90번째 백분위수이며 상위 10%의 평균이 아니다. 코너 거리 기반 평가는 팔레트 키포인트의 직접적인 정확도를 다루는 선행 [26]과 같은 평가 목적이지만, 평균·중앙값·축척이 다르므로 보고 숫자를 직접 비교하지 않는다.

Percentage of Correct Keypoints(PCK)는 임계 거리 이내의 코너 비율이다. PCK@10px는 10픽셀 이내인 예측 수를 전체 주석 코너 수로 나눈 백분율이며 결측·매칭 실패는 정답으로 인정하지 않는다. 주석이 없는 물리적 코너까지 평가했다는 의미는 아니다. 전체 실패 별점 P90은 결측·매칭 실패에 영상 대각선 길이를 부여한 별도 통계이다. 조건부 오차와 이 전체 통계를 함께 해석한다.

위치 오차 e_t 는 미터 단위 위치 벡터의 거리, 회전 오차 e_R 는 객체가 허용하는 회전 집합 $\mathcal{G}$ 안의 최소 회전각 차이이다. 참조는 $\mathbf{R}^*$, $\mathbf{t}^*$, 예측은 $\hat{\mathbf{R}}$, $\hat{\mathbf{t}}$ 로 표시한다.

$$e_t = 100\|\hat{\mathbf{t}} - \mathbf{t}^*\|_2 \quad [\text{cm}], \quad (12)$$

$$e_R = \frac{180}{\pi} \min_{Q \in \mathcal{G}} \arccos \left[\text{clip} \left(\frac{\text{tr}((\mathbf{R}^* Q)^T \hat{\mathbf{R}}) - 1}{2}, -1, 1 \right) \right]. \quad (13)$$

객체 대칭을 명시적으로 정의한다는 평가 원칙은 BOP [43]와 관련되지만, 각 프로젝트의 점·참조 정의가 같은 것은 아니다. 본 위치·회전 참조는 영상 주석과 물체 기하로 재구성한 값이며 독립 물리 계측의 정답이 아니다. 자세가 산출된 영상의 중앙값·P90과 전체 영상에 대한 자세 산출물을 함께 보고한다. 산출물은 정답물이 아니며, 정답 박스 매칭을 자세 추론의 입력 또는 성공 게이트로 사용하지 않는다. 따라서 코너 매칭 영상과 자세 산출 영상의 집합은 같지 않을 수 있다.

방향각 오차, 방향을 고려한 3차원 Intersection over Union(IoU), 8코너에 전체 회전 동등성을 적용한 Average Distance of Model Points(ADD)의 변형 ADD_{sym}은 보충 자료에 제시한다. 정확도 곡선 아래 면적 AUC(Area Under the Curve)는 객체 대각선으로 정규화한 오차의 0-0.1 범위에서 적분·정규화하며 자세 실패를 전체 분모에 남긴다. 이는 자유로운 최근접 표면 대응 ADD-S와 다르다. 추가 영상 지표의 정의와 원수치도 보충자료에 보존한다.

E. 집계, 불확실성과 큰 오류 분석

학습 방법의 값은 각 seed에서 계산한 통계량의 산술평균이다. 예측 앙상블이나 모든 seed의 점을 한꺼번에 모은 중앙값이 아니다. 13개 세션을 단위로 10,000회 짝지어 재표집하고, 각 재표집 안에서 세 seed의 통계 차이를 평균해 2.5·97.5 백분위 구간을 계산한다. 초기 난수는 20260917이며 같은 재표집을 사용한다. 주 변화량은 $\text{median}(e_{\text{after}}) - \text{median}(e_{\text{before}})$ 로, 프레임별 차이의 중앙값과 구분한다. 이 구간은 반복 개발자료의 사후 기술 통계이며 다중 비교·개발 중 선택 편향을 보정한 독립 확증이 아니다. 정사각형 한 세션의 세션 간 일반화 구간은 산출하지 않는다.

큰 오류 분석은 초기 예측에서 정한 하나의 참조 대응을 보정 후에도 고정한다. 주 코너 지표가 각 예측의 허용 전체 대응을 선택하는 것과 구분하여 이동 상한의 효과를 진단한다. 초기 오차가 한계 안인지 밖인지, 원래 좋은 코너의 손상, 큰 오류 복구, 2D와 위치·회전의 공동 변화를 기록하며 표본 제외나 파라미터 선택에는 사용하지 않는다. 미측정·미확인 수치는 x, 정의되지 않는 통계는 NA로 표기한다.

자료에서 방법을 반복 선택·수정하면 유한 평가 표본의 변동을 선택 과정이 이용할 수 있다 [44]. 따라서 세션 재표집을 수행하더라도 재사용한 319장의 DEV 역할을 새로운 최종 TEST로 바꾸지 않는다. 자세 참조가 같은 2D 레이블과 PnP에서 생성되면 코너 오차와 자세 오차에 공통 참조·교정의 상관이 남는다. 측정 불확실성의 공분산 항을 기록해야 한다는 지침 [45]과 구별하여, 이 원고의 bootstrap 구간은 물리 참조 불확실성을 포함한 완전한 계측 구간으로 주장하지 않는다.

V. 결과와 분석

A. 여러 기반 추정기에서의 보정 효과

표 V는 같은 319장에 대한 각 기반의 Base와 N3를 비교한다. 코너 오차 중앙값은 YOLO에서 6.721에서 5.778픽

셀, DOPE에서 12.570에서 7.469픽셀, ResNet에서 8.223에서 7.085픽셀로 감소하였다. PCK@10px도 각각 63.425%에서 68.587%, 24.170%에서 44.338%, 52.261%에서 57.223%로 증가하였다. 동일 보정 절차를 기반별로 학습했을 때 초기 코너의 중심부 정확도와 전체 주석 기준 성공 코너 비율이 개선되었다.

위치·회전 중앙값의 점추정도 세 기반에서 감소하였다. 표 VI에서 YOLO와 DOPE의 두 중앙값 변화는 사후 세션 구간에서도 음수였다. 반면 ResNet의 위치 중앙값 차이 구간은 $[-2.077, 0.202]$ cm로 0을 포함한다. 세 기반의 점추정 감소를 모든 자세량의 확증적 개선으로 해석하지 않는다. 전체 P90·방향각 구간과 seed별 편차는 보충자료에 제시한다.

큰 오류에는 개선과 악화가 함께 존재한다. DOPE의 코너 P90은 51.282에서 53.570픽셀로 증가했고, 회전 P90 차이도 약 +1.590도였다. ResNet의 위치 P90은 약 +2.759cm 증가하였다. 각 기반·seed의 보정 전후 자세 산출 ID 집합은 같았으며 신규 자세 실패·복구는 0이었다. DOPE의 자세 산출은 210/319장으로, 실패 109장은 전체 분모에 남았다. 이는 N3가 결측이나 잘못된 검출을 새롭게 복구하는 방법이 아니라는 범위와 일치한다.

코너의 조건부 P90과 전체 실패 포함 통계도 다르다. YOLO의 조건부 P90은 43.890에서 42.134픽셀로 낮아졌지만, 실패 별점 포함 전체 P90은 61.710에서 61.715픽셀로 거의 변하지 않았다. 따라서 관찰된 국소 보정 효과를 전체 극단 오류의 해결로 확대하지 않는다.

B. 치수와 회전 대응 감독의 추가 효과

표 VII는 동일한 YOLO의 통계 구성 N0-N3를 비교한다. 영상 기반 N0에 치수 분기를 추가한 N2의 코너 중앙값은 5.944에서 5.778픽셀로 감소했고, PCK@10px은 약 1.054퍼센트포인트 증가하였다. 위치·회전 중앙값도 7.260cm·2.176도에서 7.011cm·2.090도로 낮아졌다. 정확한 N2-N0 코너 중앙값 차이는 약 -0.1662px이다. 이 변화는 치수 분기 추가의 관측 효과이며 정보 내용과 추가 파라미터의 독립 효과를 완전히 분리한 결과는 아니다. Base-N3의 더 큰 변화에는 국소 영상 분포와 추가 학습 전체가 포함된다.

회전 대응만 추가한 N1은 N0보다 위치·회전 중앙값이 소폭 높았다. 치수 보정에 회전 대응을 추가한 N3도 N2와 코너 중앙값·PCK@10px이 거의 같았으며, 위치 중앙값은 7.011에서 7.068cm로 증가하고 회전 중앙값은 2.090에서 2.070도로 감소하였다. 코너 P90은 약 0.326픽셀 낮아졌으나 변화 방향은 지표별로 달랐다. N3-N2 코너 중앙값 차이는 약 +0.0004884px이다. 대칭 감독의 일반적 필요성이나 전체 개선의 주원인으로 해석할 근거는 제한적이다.

실제 학습에서 원래 번호와 다른 전체 대칭 대응을 선택한 노출은 DOPE의 seed별 290·290·289회로 약 0.3%였고, ResNet에서는 모두 0회였다. 합성 학습의 네 방향 회전 대응 행동 0개였다. 동일한 감독 절차를 적용했다는 사실과 그 절차가 목표를 실제로 바꾼 빈도를 구분해야 한다. 별도 정사각형 평가의 개선을 네 방향 대응 학습의 전이 효과로 설명하지 않는다.

C. 다른 보정 방법과의 비교

표 VIII는 같은 초기 예측과 319장·8코너 평가에서 보정 방법들의 최종 결과를 비교한다. 제안 N3의 코너 중앙값은 직접 회귀 D와 선 구조 L보다 낮았다. 그러나 PoseFix 기반

방법은 코너 중앙값 5.561픽셀, 위치 중앙값 6.951cm, 회전 중앙값 2.028도로 N3보다 낮았고 PCK@10px도 더 높았다. N3의 코너 P90은 42.134픽셀로 PoseFix 기반 방법의 43.907픽셀보다 낮았다.

이 비교는 내부 특징·원영상 사용, 출력 방식, 손실과 감독 조건이 다른 전체 방법 비교이다. N3의 구조적 특징은 기존 특징과 치수를 이용해 제한된 좌표 이동을 학습한다는 데 있으나, 그것만으로 다른 보정 방법보다 정확하거나 효율적이라고 결론내리지 않는다. 입력·감독·손실의 차이를 유지한 방법 전체 비교이며, 아래의 Base/N3/PoseFix 비용 비교는 같은 실행환경·최종 PnP 경계로 새로 측정했다. 정확도 표의 N3/PoseFix 값은 세 seed의 통계 평균이고 비용 표는 사전에 고정된 seed 1의 실행이다. 비용을 다른 seed의 정확도나 모든 비교군의 동일 총학습 예산을 입증하는 값으로 쓰지 않는다.

D. 재질과 정사각형으로의 적용 범위

직사각형 플라스틱 194장에서 코너 중앙값은 Base의 7.509에서 N3의 6.203픽셀로, 목재 125장에서는 6.124에서 5.274픽셀로 낮아졌다. 두 집단의 PCK@10px과 위치·회전 중앙값도 감소 또는 증가의 개선 방향을 보였다. 재질별 통계와 최신 사람 입력 등급별 보조 통계는 서로 다른 분류이며, 등급 판정 기준은 아직 미확인이다. 집단의 시점·가림·촬영 조건이 달라 재질 자체의 인과 효과로 해석하지 않는다. 전체 재질별 행은 보충자료에 제시한다.

표 IX의 정사각형 전체 수동 참조 모드에서 코너 중앙값은 YOLO 5.526에서 5.004픽셀, DOPE 11.748에서 7.037픽셀, ResNet 6.584에서 5.891픽셀로 낮아졌다. 영상 내부 600코너 모드에서도 각 기반의 보정 전후를 같은 분모로 제시한다. 두 모드 모두 2D 보정의 관측 근거이나, 한 촬영 세션·한 치수의 결과이므로 새로운 임의 개체·환경에 대한 일반화 범위는 제한된다.

정사각형에서도 대칭 감독의 추가 이득은 확인되지 않았다. 전체 수동 모드에서 YOLO N3-N2는 코너 중앙값 약 +0.055픽셀, PCK@10px 약 -0.332퍼센트포인트였다. Base 대비 전체 보정의 이득과 N2 대비 대칭 감독의 추가 효과는 별개의 비교이다. 독립 표준 자세 참조가 없어 두 모드의 위치·회전 정확도는 모두 x이다.

E. 사람 입력 등급의 보조 분석과 큰 오류의 한계

표 X는 없음 153장, 중간 92장, 어려움 74장의 사람 입력 등급(기준 미확인)에 대한 사후 분석이다. 없음·중간에서는 코너 중앙값·P90과 위치·회전 중앙값이 Base보다 N3에서 낮았다. 어려움에서는 코너 중앙값이 11.045에서 10.117픽셀로 낮아졌지만, 코너 P90은 55.149에서 55.929픽셀로 높아졌다. 위치 중앙값도 16.047에서 17.481cm로 악화했다. 회전 중앙값의 46.101에서 26.483도로의 감소가 모든 프레임의 개선을 뜻하지는 않는다. 중앙 순위와 자세 가설 변화가 함께 포함된 결과이며 외부 가림 복원 능력의 독립 확증으로 해석하지 않는다.

현재 등급은 플라스틱 194장·목재 125장을 모두 포함한다. 등급을 최신 버전으로 연결해 집단별 통계를 다시 계산했지만 전체 319장의 기존 2D·6D 결과와 실패 분모는 그대로 유지되었다. 코너 가시성도 원래 참조 좌표에 상태만 연결한 보조 결과이며, 직접 보이는 점과 기하로 보완된 참조를 동일한 독립 수동 정답으로 간주하지 않는다. 정사각형 119의 가시성 분석은 전체수동 602점과 영상내 600점 모드를 별도

TABLE V

세 기반 추정기의 보정 전후, 같은 기반 안의 동일 초기 출력에 N3를 적용한다. 조건부 자세 통계의 분모가 기반별로 달라 기반 간 순위표가 아니다.

기반	경로	코너 중앙값 (px)	코너 P90 (px)	PCK@10px (%)	위치 중앙값 (cm)	회전 중앙값 (도)	2D 매칭 영상	유효 예측 코너	자세 산출 (%)
YOLO	Base	6.721	43.890	63.425	7.897	2.539	311/319	2,445	100.00
YOLO	N3	5.778	42.134	68.587	7.068	2.070	311/319	2,445	100.00
DOPE	Base	12.570	51.282	24.170	10.046	3.530	233/319	1,797	65.83
DOPE	N3	7.469	53.570	44.338	8.356	3.051	233/319	1,797	65.83
ResNet-18 [†]	Base	8.223	62.638	52.261	9.739	4.342	292/319	2,291	100.00
ResNet-18 [†]	N3	7.085	62.371	57.223	9.134	3.832	292/319	2,291	100.00

전체 319장·참조 2,499코너. 코너 중앙값·P90은 유효 매칭 코너에, 위치·회전은 산출된 자세에 조건부이다. YOLO Base/N3 자세는 전체 319/319장이며 2D 매칭 311/319장과 구분한다. N3는 세 seed의 통계 평균이며 양상불이 아니다. [†]10-epoch CONSTANT-fold RGB 모델. 기반별 매칭·자세 산출 집합은 다르므로 조건부 오차만으로 기반의 절대 순위를 정하지 않는다.

TABLE VI

N3-Base 위치·회전 중앙값 변화의 사후 95% 구간.

기반	지표	차이	95% 구간
YOLO	위치(cm)	-0.829	[-1.653, -0.195]
YOLO	회전(도)	-0.468	[-0.886, -0.092]
DOPE	위치(cm)	-1.690	[-2.796, -0.786]
DOPE	회전(도)	-0.479	[-0.893, -0.196]
ResNet-18 [†]	위치(cm)	-0.604	[-2.077, 0.202]
ResNet-18 [†]	회전(도)	-0.510	[-0.714, -0.022]

13세션의 10,000회 짝지는 채표집. 음수는 오차 감소이다. ResNet 위치 구간은 0을 포함한다. P90·방향각·seed 편차는 보충자료에 제시한다.

로 유지한다. 다른 기반에서도 악화를 보존하였다. DOPE의 중간 집단 위치 중앙값은 15.499에서 16.867cm, 어려움 집단은 14.327에서 16.818cm로 높아졌다. ResNet 어려움 집단의 위치 중앙값은 33.668에서 34.043cm, 회전 중앙값은 51.270에서 54.608도로 악화하였다.

초기 코너 오차를 e_k , 원본 영상에서의 이동 상한을 $c_i = 0.01D_{I_i}$ 라 하면, 고정 참조 대응에 대해 다음 하한이 성립한다.

$$e'_k \geq \max(0, e_k - c_i). \quad (14)$$

640×480 영상에서는 상한이 8픽셀이므로 초기 오차 50픽셀을 한 번에 42픽셀보다 작게 만들 수 없다. 이는 제한된 이동의 기하적 성질이지, 현재 모든 큰 오류의 원인이 이동 제한이라는 실험적 결론은 아니다.

표 XI에서 초기 오류가 상한 밖인 코너는 981/2,445개였다. N3가 20픽셀 초과 오류를 10픽셀 미만으로 복구한 코너 수는 seed별 0·2·0개였고, 5픽셀 미만 오류를 10픽셀 초과로 악화시킨 수는 0·0·1개였다. 기록된 이동 상한 도달은 64/2,445 코너(2.62%)이며 대부분의 코너가 cap에 막혔다는 설명은 성립하지 않는다. 2%/무제한 실험의 코너 중앙값 5.762px·P90 42.62px도 이미 완료된 별도 결과다. 코너가 좋아져도 이동이 악화된 영상은 seed별 98/78/100장(동일 311장 분모)이어서 2D 개선을 6D 개선으로 대체하지 않는다. 최종 효과는 큰 오류의 전반적인 복구보다 국소 정밀도 개선에 가깝다.

그림 4는 코너가 참조에 가까워지는 사례와 처음에는 정확했던 점이 소폭 악화되는 사례를 함께 보여준다. 표시된 사례 오차는 해당 영상의 평균 코너 오차이며, 주표의 전체 코너 풀링 중앙값과 다르다. 큰 오차가 27.21에서 25.42픽셀로 줄어든 예도 완전한 복구가 아니라 부분적인 감소이다. 이 예시를 새 정사각형 또는 가림 등급 전체를 대표하는 확률 표본으로 해석하지 않는다.

F. 추가 비용과 추정기 업데이트 대안

주 비용 비교는 아래 표 XIII의 같은 환경·동기화 벽시계 경계이다. 이전 세 기반의 CUDA event 계측은 보충자료에 별도 보존하며 YOLO 환경과 DOPE/ResNet 환경을 합쳐 비용 순위를 만들지 않는다. GPU event의 N3 head-only 중앙값과 전체 벽시계 중앙값 차이는 다른 계측량이다. 비용 수치를 Jetson 시간이나 모든 대안의 효율 우월성으로 확대하지 않는다.

표 XII는 공통 플라스틱 128장으로 제한한 추정기 업데이트 대안이다. N3의 PCK@10px은 56.244%로 보정 의사 레이블 학생의 51.472%보다 높았으며 위치·회전 중앙값도 낮았다. 합성 추가 학습과 원래 의사 레이블 학생을 포함한 대안 간 차이는 이 집합과 각 감독 예산에 한정된다. 별도 교사를 사용한 학생을 N3를 학습에 적용한 방법으로 명명하지 않으며, 자기학습 전체가 열등하거나 과적합이 실패 원인으로 확정됐다고 해석하지 않는다.

G. 같은 실행 경계의 Base/N3/PoseFix 비용

표 XIII의 주 시간은 native BGR 영상이 메모리에 있는 상태에서 전처리, 동결 검출기·공유 특징 포착, 보정기의 crop/표본화·디코더와 최종 prediction-only W/D+PnP를 모두 포함한 동기화 벽시계 시간이다. 영상 파일 decoding과 모델 loading은 제외한다. 원래 모델별 수치 계약을 유지했으며 원결과와의 점 좌표 차이는 Base/N3 0px, PoseFix 최대 0.000122px로 0.001px 검산 허용 오차 이내였다. 첫 450호출은 YOLO의 cuDNN TF32 계약 차이로 폐기했고, 정정된 450호출 중 준비 60회와 측정 390회를 구분했다. 새 학습은 0회다.

VI. 기록 영상의 고정 모델 오프라인 사례 연구

본 사례는 리프터 운용 중 저장된 네 RGB 영상 8,910프레임에 Base와 Base+N3를 각각 한 번 적용하여 코너·자세의 연속 출력을 비교하는 오프라인 평가이다. 촬영 당시 특정 팔레트에 맞춰 학습한 운용 모델과 논문 평가 모델을 구분하고, 두 평가 경로의 전처리·카메라·치수·좌표계를 고정하였다. 시간축 추적에 포함된 팔레트 연구 [13]와 달리 새로운 추적기나 제어기를 제안하지 않는다. 두 방법은 각각 8,772 프레임에서 새 자세를 산출했고, 이전 출력 유지 없이 138 프레임이 no-pose였다.

CSV의 운용 모델 추정값이나 제어 명령은 독립 정답이 아니다. 영상 시각과의 대응, 물체 원점·축·단위를 확인한 뒤 동작 구간 구분에 사용하고, 독립 거리·각도 정확도와 직접 가시 코너 정확도는 해당 참조가 확보된 항목만 평가한다.

TABLE VII

동일 YOLO의 구성 요소 절제. 국소 보정에 치수·회전 대응을 추가한 효과를 분리한다. Base 대비 전체 보정 이득과 N0/N2/N3의 작은 요소별 차이를 구분한다.

구성	코너 중앙값 (px)	코너 P90 (px)	PCK@10px (%)	위치 중앙값 (cm)	위치 P90 (cm)	회전 중앙값 (도)	회전 P90 (도)
N0: 영상 보정	5.944	42.872	67.534	7.260	38.391	2.176	85.973
N1: 영상+회전 대응	5.921	42.513	67.560	7.274	39.128	2.183	85.989
N2: 영상+치수	5.778	42.459	68.587	7.011	38.108	2.090	85.819
N3: 제안 보정	5.778	42.134	68.587	7.068	37.809	2.070	85.919

319장·8코너 평가, 세 seed의 통계 평균. 각 구성의 자세 산출은 319/319이다. N3-N2의 변화는 지표별로 다르며, 치수 정보와 추가 파라미터 효과도 완전히 분리된 것은 아니다. 세부 방향각·겹침·정규화 영상 오차는 보충자료에 보존한다.

TABLE VIII

동일 319장·8코너 평가에서의 보정 방법 비교. 입력·손실·감독이 다른 방법 전체 비교이며 세 seed 통계의 산술평균이다.

방법	코너 중앙값 (px)	코너 P90 (px)	PCK@10px (%)	위치 중앙값 (cm)	회전 중앙값 (도)
Base	6.721	43.890	63.425	7.897	2.539
영상 보정 P	5.938	42.631	67.494	7.153	2.154
직접 회귀 D	6.504	42.992	64.372	7.597	2.274
선 구조 L	6.146	42.984	66.867	7.548	2.233
PoseFix 기반	5.561	43.907	68.707	6.951	2.028
제안 보정 N3	5.778	42.134	68.587	7.068	2.070

Base는 보정 없음, P는 별도 실행의 영상 기반 보정으로 N0와 다른 가중치이다. 같은 평가 집합이 입력·손실·사전학습·선택 예산의 동등성을 의미하지 않는다. PoseFix 기반 방법이 유리한 중앙값을 유지한다.

TABLE IX

정사각형119장의 동일 고정 예측을602/600점 참조 모드로 각각 평가.

기반	방법	중앙값(px)	P90(px)	PCK@10px(%)	유효	참조	위치(cm)	회전(도)
(a) 전체수동 참조602점								
YOLO	Base	5.526	11.439	85.216	597	602	x	x
YOLO	N2	4.949	9.882	89.590	597	602	x	x
YOLO	N3	5.004	9.932	89.258	597	602	x	x
DOPE	Base	11.748	30.226	36.711	549	602	x	x
DOPE	N3	7.037	28.244	64.618	549	602	x	x
ResNet-18	Base	6.584	17.073	72.425	592	602	x	x
ResNet-18	N3	5.891	15.872	78.350	592	602	x	x
(b) 영상내 참조600점								
YOLO	Base	5.521	11.473	85.333	595	600	x	x
YOLO	N2	4.940	9.867	89.667	595	600	x	x
YOLO	N3	4.980	9.919	89.333	595	600	x	x
DOPE	Base	11.748	30.226	36.833	549	600	x	x
DOPE	N3	7.037	28.244	64.833	549	600	x	x
ResNet-18	Base	6.595	17.078	72.333	590	600	x	x
ResNet-18	N3	5.898	15.891	78.278	590	600	x	x

한 촬영세션·등록 치수[1.1,1.1,0.15]m. N3는 세seed 통계의 평균이며 양상불이 아니다. 두 모드는 화면 밖 참조2점 포함 여부만 다르며 분모를 혼합하지 않는다. 독립6D 참조 부재로 위치·회전은x, 세션간 구간은NA다. N3대Base와 N3대N2는 별도 비교다. ResNet은10-epoch CONSTANT-fold RGB 기준 모델이다.

사람이 확인한 PnP 보조 기하 참조의 영상 오차는 별도 탐색 패널로 구분한다. 완료된 no-pose 구간의 최장은 두 방법 모두 2.535초였고 25개 저장 프레임을 포함했다. 센서 기록 공백은 이 값에 포함하지 않았으며, 저장되지 않은 프레임의 상태를 추정하지 않았다.

세션 경계를 제외하고 양쪽 자세가 모두 유효한 인접 8,737쌍에서 Base와 N3의 $|\Delta x|$ 중앙값은 각각 0.094와 0.100cm, $|\Delta z|$ 중앙값은 0.298와 0.320cm, $|\Delta \psi|$ 중앙값은 0.108과 0.114도였다. P90은 x 와 z 에서 각각 0.609→0.593cm와 2.150→2.059cm로 낮아졌고 방향각은 0.431→0.436도로 높아져 변화가 혼합되어 있다. 이 값은 이동과 정지를 함께 포함한 인접 출력 변화이며 정지 잡음이나 정확도가 아니다. 별도 12장의 주석은 버전별로 보존하였다. 원래 G 저장본의

기하 참조는 직접 클릭 66점과 PnP 투영 30점이며, 이후 가시성 재검수본은 직접 클릭 좌표 72점과 자체 가림 상태 24개다. 두 버전의 좌표를 섞지 않았다. 이번 별도 기하 참조 패널에는 원래 G 저장본의 96좌표만 사용했고, 사람이 고정 선택 박스를 확인하여 12장 모두 같은 대상으로 판정하였다. 공식 120장·24장 반복 검수의 직접 가시 코너 계약은 이 별도 패널로 완료 처리하지 않았다. 확인된 정지 구간과 독립 물리 참조도 없어 관련 값은 x로 유지한다.

원래 참조와 고정 원시 예측을 대조한 표 XIV에서는 중앙 오차가 3.974→4.184px로 악화되었지만 P90은 9.643→8.977px, PCK는 88/96→91/96(91.667→94.792%)으로 개선되어 결과가 혼합되었다. 모든 점과 네 세션을 유지했으며 오차를 보고 표본·seed를 고르지 않았다. 기하 보조

TABLE X

319장의 사람 입력 등급(기준 미확인)에 따른 YOLO Base와 N3 보조 분석.

사람 입력 등급	방법	영상	코너 중앙값 (px)	코너 P90 (px)	PCK@10px (%)	위치 중앙/P90 (cm)	회전 중앙/P90 (도)	참조/유효 예측 코너
전체	Base	319	6.721	43.890	63.425	7.897 / 40.530	2.539 / 86.527	2,499 / 2,445
전체	N3	319	5.778	42.134	68.587	7.068 / 37.809	2.070 / 85.919	2,499 / 2,445
없음	Base	153	5.275	18.965	74.223	4.668 / 19.837	1.716 / 50.874	1,222 / 1,222
없음	N3	153	4.547	15.301	80.742	4.361 / 16.117	1.503 / 6.612	1,222 / 1,222
중간	Base	92	7.603	103.611	61.905	7.851 / 26.036	1.999 / 86.159	714 / 714
중간	N3	92	6.256	102.597	66.527	6.124 / 23.492	1.841 / 85.631	714 / 714
어려움	Base	74	11.045	55.149	41.918	16.047 / 256.294	46.101 / 88.734	563 / 509
어려움	N3	74	10.117	55.929	44.819	17.481 / 260.743	26.483 / 88.556	563 / 509

등급은 최신 사람 입력을 원본 RGB 해시와 frame ID에 연결한 것이다. 판정 기준의 사람 확인은 아직 없어 외부 물체 가림의 경우 완료로 부르지는 않는다. 자체 가림·화면 밖을 포함했는지와 사전 예측 노출을 통제된 독립 시험이 아니며, 보조 사후 분석으로 제시한다. 전체 319장의 원래 2D·6D 분모와 수치는 유지했다.

TABLE XI

국소 보정의 복구 범위와 손상. 각 칸은 seed 1 / 2 / 3의 실제 개수이다. 좋은 코너의 손상과 최종 6D 변화의 분모를 분리한다.

항목	Base→P	Base→N3
(a) 코너 수: 유효 평가 예측 2,445개		
초기 오차가 이동 상한 이내	1,464 / 1,464 / 1,464	1,464 / 1,464 / 1,464
초기 오차가 이동 상한 밖	981 / 981 / 981	981 / 981 / 981
양호(< 5px)→악화(> 10px)	0 / 1 / 0	0 / 0 / 1
큰 오차(> 20px)→복구(< 10px)	0 / 0 / 0	0 / 2 / 0
(b) 영상 수: 2D 매칭 공동 분석 311장		
코너·위치·회전 모두 개선	114 / 113 / 112	126 / 129 / 124
코너 개선, 위치 또는 회전 악화	138 / 140 / 138	147 / 129 / 141

참조 대응을 초기 예측 기준으로 고정한 진단이다. 각 코너의 이동 상한은 원본 영상 대각선의 1%이다. 한계 안팎의 모든 개선·무차이·악화 개수는 보충자료에 함께 남긴다.

TABLE XII

플라스틱 공통 128장에서 추정기 업데이트와 출력 보정의 비교.

경로	코너 중앙값 (px)	코너 P90 (px)	PCK@10px (%)	위치 중앙값 (cm)	회전 중앙값 (도)
Base	9.565	40.902	49.137	9.353	3.530
합성 추가 학습	9.741	41.776	48.629	9.203	3.507
원래 의사 레이블 학생	9.961	41.958	47.513	9.226	3.942
보정 의사 레이블 학생	8.954	42.085	51.472	9.186	3.766
Base+N3	8.290	40.089	56.244	8.117	2.900

모든 행의 집합은 128장·전체 참조 985코너·유효 예측 931코너이다. 반복 개발 부분집합이며 독립 시험이 아니다. 별도 교사와 감독을 사용한 학생을 N3 학생으로 부르지는 않는다. 학습·감독 예산이 같은 단일 요인 비교는 아니다.

참조의 생성 시점에 예측 노출을 독립 통제했는지는 확인되지 않았고, 이번 대상 대응 단계에서 선택 박스를 보았다는 사실은 기록했다. 따라서 이 사례로 독립 블라인드 코너 복원, 물리 자세 정확도, 추적 정확도, 포크 삽입 성공률 또는 정렬시간 개선을 주장하지 않는다.

추가 자료 인계 후 원영상 8,910개 저장 픽셀과 센서·host 시각의 대응을 대조했고 중복 관측 29개를 보존하였다. 정사각형 119장의 원사진과 원주석 해시도 일치하여 602/600 점 모드를 그대로 재사용하였다. 리프터 요약 출력과 달리 원시 내부 기록에는 각 방법의 유효한 전체 3D 이동·회전 예측 8,772개가 이미 존재한다. 그러나 정사각형과 리프터의 9,029개 대상 관측에 독립 실측으로 연결된 참조는 0개이므로 물리 T/R의 x를 교체하지 않았다. 중립 CAN 명령 32구간의 8,263개 저장 출력은 별도 사후 기술 자료로 대조했으며 실제 상대 정지가 확인되지 않아 정지 잡음으로 해석하지 않는다. 공식 직접 가시 참조·반복 검수의 미완료 상태와 완료된 기하

보조 참조를 구분한 연결 검산은 보충자료에 제시한다.

VII. 논의와 한계

A. 현재 결과가 지지하는 범위

이미 학습된 추정기의 코너를 수정한다는 개념과 치수·대칭 활용 자체는 선행연구에 존재한다. 본 결과가 보여주는 것은 내부 영상 특징과 알려진 치수로 제한된 이동을 학습했을 때, 세 기반에서 중심부 오차가 어떻게 줄고 어떤 실패가 남는지이다. 여러 기반의 결과는 각 기반에 별도로 학습한 보정기의 적용성으로 해석해야 한다. 초기 디코더와 검출 조건까지 완전히 같게 만든 백본 치환 실험이나 하나의 가중치를 임의 추정기에 전이한 결과는 아니다.

Base 대비 이득에는 추가 보정 학습 전체의 효과가 포함된다. N0-N3 절제는 치수 분기와 회전 대응의 역할을 더 좁히지만 치수 내용과 파라미터 효과를 완전히 분리하지 못한다.




Fig. 4. 동일한 기존 영상·좌표의 보정 예시. 그림은 고정 seed 1을 표시하고, 사례 선정에는 세 seed의 영상별 평균 코너 오차 변화가 사용되었다. 수치는 알려진 코너 0~7의 대칭 고려 영상별 평균으로 주표의 폴링 중앙값과 다르다. 원래 예시의 영상과 확대 영역을 자르고 설명 레이블만 재배치했으며 코너 위치를 변경하지 않았다. 큰 오류의 부분 감소와 소폭 악화를 함께 보존한다.

TABLE XIII

같은 RTX 3080/pallet-yolo26 환경의 전체 벽시계 비용. 모델별 원래 수치 계약을 보존한 Base/N3/PoseFix 방법 전체 비교.

방법	중앙(ms)	P90(ms)	자세 산출
Base	11.056	13.081	130/130
N3 seed 1	14.470	17.170	130/130
PoseFix 방식 seed 1	25.239	27.311	130/130

13세션의 고정 26프레임, batch 1, arm별 준비 20회와 프레임당 5반복. 같은 최종 PnP까지 포함한다. 파일 decoding·모델 loading 제외. CUDA/head-only 수치와 구분한다. 모든 모델이 동시에 resident한 process memory peak는 독립 방법별 메모리 비교에 쓰지 않는다. 출처: 새 RUNTIME_MATCHED/RUNTIME_VERIFICATION.json.

치수 입력이 후보 점수에 영향을 준다는 것과 최종 코너가 물리 형상을 일관되게 복원한다는 것도 다르다. 더 강한 형상 일관성이나 초기 추정기 직접 치수 입력의 이득은 이 후단 보정 결과로 대체할 수 없다.

B. 대안 선택과 실패의 의미

N3에 포함된 회전 대응 감독의 추가 이득은 작거나 혼잡되어 있다. N2를 더 단순한 후보로 논의할 수는 있으나, N3

TABLE XIV

사람이 확인한 PnP 보조 기하 참조의 별도 12장 탐색 패널. YOLO Base와 N3(seed 1).

방법	중앙(px)	P90(px)	PCK(%)	적중	유효/실패
Base	3.974	9.643	91.667	88/96	96/0
N3	4.184	8.977	94.792	91/96	96/0

4세션·12장·96개 기하 코너의 고정 분모다. 원래 직접 클릭 66점과 G로 채운 PnP 투영 30점을 같은 규칙으로 사용한다. PCK는 오차 < 10px이며 잘못된 대상·결측은 실패로 유지한다. 중앙값/P90은 유효 일치점 조건부 통계다. 공식 120장/24장 가시 코너 계약이나 독립 물리 T/R 정확도에 해당하지 않는다.

의 결과를 N2의 결과로 바꾸어 부를 수는 없다. PoseFix 기반 보정도 여러 중앙값에서 N3보다 우수하므로, P90 하나만으로 제안 방법을 전반적으로 우월하다고 결론내리지 않는다. 동일 RTX 3080/pallet-yolo26 환경에서 N3/PoseFix의 비용 차이는 확인했다. 다만 입력·손실·총학습 및 선택 예산은 완전하게 일치하지 않으므로 정확도·비용의 방법 전체 손익을 조건부로 해석한다.

사람 입력의 어려움 집단에서 위치 오차가 악화하고 큰 오류 복구가 드물다는 결과는 방법의 작동 범위를 제한한다.

TABLE XV

네 기록 영상 8,910프레임의 고정 모델 오프라인 출력.

항목	Base	Base+N3
평가 영상 / 저장 프레임	4 / 8,910	4 / 8,910
가시 코너 중앙값 / P90 (px)	x/x	x/x
새 자세 산출률 (%)	98.451	98.451
최장 완료 no-pose 구간 (초)	2.535	2.535
인접 $ \Delta x $ 중앙/P90 (cm)	0.094 / 0.609	0.100 / 0.593
인접 $ \Delta y $ 중앙/P90 (cm)	0.298 / 2.150	0.320 / 2.059
인접 $ \Delta \theta $ 중앙/P90 (도)	0.108 / 0.431	0.114 / 0.436
정지 구간 전방 변동 (cm)	x	x
정지 구간 횡방향 변동 (cm)	x	x
정지 구간 방향각 변동 (도)	x	x
전방 거리 참조 오차 (cm)	x	x
횡방향 참조 오차 (cm)	x	x
방향각 참조 오차 (도)	x	x

두 방법의 fresh/held/no-pose는 각각 8,772/0/138이다. 인접 변화는 양쪽 출력 이 유효한 같은 8,737쌍의 절댓값이며 이동과 정지를 함께 포함한다. 변동은 확인된 정지 구간의 표준편차를 뜻하므로 사람 확인 전까지 x다. 이 표의 가시 코너 정확도는 공식 120장/24장 참조 계약에 해당하며 x를 유지한다. 별도 12장 PnP 보조 기하 참조 오차는 표 XIV에 구분한다. 독립 물리 정확도는 x다.

출력 박스와 점수 보존은 검출 경로에 개입하지 않았다는 뜻이며, 원래 정확한 코너나 자세를 항상 보존했다는 뜻은 아니다. 코너 개선이 자세 개선으로 전달되는지 직접 확인한 이유도 여기에 있다.

C. 자료와 측정의 제한

직사각형 319장은 재사용 개발자료이고 정사각형은 한 세션·한 치수이다. 직사각형·정사각형의 사람 입력 등급과 참조 코너 가시성은 확보했으나, 등급 판정 기준의 사람 확인은 아직 없고 예측 노출·표본 모집 이력이 독립적으로 통제된 것은 아니다. 두 128장 집합의 frame ID는 전수 일치했으나, 실제 개체 수·선정 이력 및 과거 정사각형 자료와의 전체 노출 관계는 추가 확인 대상이다. 등급 입력 완료를 외부 가림 기준의 승인으로 바꾸지 않았으며, 과거 정사각형 150장의 7세션 자료는 현 119장 평가에 합산하지 않았다.

자세 참조는 수동 코너와 물체 기하의 재구성에 의존한다. 개별 코너 참조의 생성 경로와 작은 차이에 대한 참조 불확실성이 충분히 정량화되지 않았으므로 독립 물리 6D 실측 정확도를 주장하지 않는다. 세션 재표집 구간은 관측 결과의 변동을 설명하지만 독립 세션 검증이나 개발 중 선택 편향 보정을 대신하지 않는다. 기록 영상 사례와 정사각형의 독립 자세 정확도는 실제 참조가 검증된 뒤 별도로 완성해야 한다.

D. 작은 개선과 독립 측정의 다음 단계

치수 입력과 대칭 감독의 약한 추가 이득, 상한 도달 2.62%, 2D 개선 뒤 이동 악화는 서로 다른 관측이다. 이들만으로 모델 용량 부족이나 상관된 코너 오류가 지배 원인이라고 확정하지 않는다. 같은 동결 특징에서 자세 결합 후보를 선택하는 제한 실험은 탐색적 보충 결과로 분리하며 기존 N3의 방법·결과를 교체하지 않는다. 공동 후보 oracle은 그 bank 안의 선택 여지만 설명하고, 후보별 생성 자세 대신 실제 prediction-only W/D+PnP 최종 출력을 채점해야 한다. 사전에 제한한 GEO/PERM 각 세 seed의 6회 학습을 완료한 보충 탐색에서 GEO의 실사 정규화 코너 오차는 N3/PoseFix보다 악화되었다. RAW/PERM 대비 음의 오차 구간도 좋은 코너 손상 때

문에 고정 보존 조건을 충족하지 못했고, 같은 전체 경계의 seed1 비용은 GEO 56.541ms 대 N3 14.433ms였다. 이 고정 후보·특징·목표·예산에서는 새 배포 이득을 지지하지 않으며, 실패를 용량이나 상관 오류의 단일 원인 증명으로 바꾸지 않는다.

실제 동일 상대 자세에서 clean/실물 가림을 취득하고 독립 참조를 설치하는 패킷을 별도로 완성하였다. 현재 8,910장 리프터와 119장 정사각형의 총 9,029개 관측 중 연결된 독립 이동·회전 참조는 0개이므로 독립 pair 평가를 완료했다고 표시하지 않는다. 32개 CAN 중립 명령 구간·8,263프레임은 실제 상대 정지 증거가 아니며, 기존 12장/96점과 후속 72점 저장본도 물리 참조로 승격하지 않는다. 작은 수치 차이를 운용상의 의미 있는 개선으로 판단하려면 참조·교정 오차와 반복성을 함께 계속해야 한다.

VIII. 결론

본 연구는 영상 기반 초기 추정기를 고정한 채, 다중 해상도 특징과 알려진 물리적 치수로 코너의 국소 이동을 학습하는 보정 방법을 평가하였다. 이동 후보의 확률 가중평균과 원본 좌표의 상한을 사용하고, 동일한 자세 계산을 통해 코너 수정과 위치·회전 변화의 관계를 비교하였다.

직사각형 실사 319장에서 세 기반의 코너 중앙 오차와 전체 주석 기준 PCK@10px이 개선되었으며, 별도 정사각형 119장에서도 2D 보정 효과가 관찰되었다. 반면 ResNet 위치 중앙값의 사후 구간은 0을 포함했고, 일부 P90과 사람 입력의 어려움 집단의 위치 오차는 악화되었다. 회전 대응 감독의 추가 효과도 일관되지 않았다. 네 기록 영상 8,910프레임에서는 Base와 N3의 자세 산출률이 같은 98.451%였고 인접 출력 변화는 지표별로 혼합되었다. 이러한 결과는 주어진 정보·학습·참조 조건에서 국소 보정의 적용 가능성과 경계를 함께 보여준다. 정사각형을 포함한 사람 입력 등급과 3,101개 참조 코너의 가시성 상태는 확보하였다. 별도 12장 PnP 보조 기하 참조에서는 P90과 PCK가 개선되었지만 중앙값은 악화되어 결과가 혼합되었다. 이 탐색 패널의 실제 대상 대응 12건은 확보했으나 공식 120/24장 가시 코너 계약과 독립 물리 자세 정확도를 대신하지 않는다. 남은 확인은 등급 판정 기준·참조 품질과 독립 물리 참조이며, 기록 영상의 정지 잡음도 확인된 정지 구간이 필요하다. 이미 입력된 등급과 가시성의 재작업을 전제로 하지 않으며, 추가 일반화는 독립 관측에서 평가해야 한다.

추가 모델 변경의 필요성과 독립 측정의 필요성은 분리된다. 기존 N3 결과와 대안의 중앙값·꼬리·실패·비용은 현재 원고에서 정리할 수 있지만, 반복 개발자료의 수치만으로 독립 물리 정확도나 실제 가림 대응을 확정할 수 없다. 제한된 자세 결합 후보 실험의 6회 학습·세 seed 비교·동일 경계 비용도 보충자료에 보존하였다. 후보 oracle 여지가 있어도 새 학습은 실용 N3/PoseFix 대비 개선을 지지하지 않았으며, 새로운 확증에는 같은 상대 자세의 실물 가림 쌍과 독립 계속 참조가 필요하다.

References

- [1] M. Seelinger and J.-D. Yoder, "Automatic visual guidance of a forklift engaging a pallet," *Robotics and Autonomous Systems*, vol. 54, no. 12, pp. 1026–1038, 2006. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0921889006001023>
- [2] J. Xiao, H. Lu, L. Zhang, and J. Zhang, "Pallet recognition and localization using an RGB-D camera," *International Journal of Advanced Robotic Systems*, vol. 14, no. 6, 2017, art. no. 1729881417737799. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/1729881417737799>

- [3] B. Molter and J. Fottner, "Semi-Automatic Pallet Pick-up as an Advanced Driver Assistance System for Forklifts," in *IEEE Intelligent Transportation Systems Conference (ITSC)*, 2019, pp. 4464–4469. [Online]. Available: <https://portal.fis.tum.de/en/publications/semi-automatic-pallet-pick-up-as-an-advanced-driver-assistance-sy/>
- [4] P. Köhne, M. Schaper, J. Lübbehäsen, B. Küster, M. Stonis, and L. Overmeyer, "Methods for autonomous load handling with forklifts: a state-of-the-art review," *The International Journal of Advanced Manufacturing Technology*, vol. 144, no. 1–2, pp. 233–259, 2026. [Online]. Available: <https://link.springer.com/article/10.1007/s00170-026-17516-9>
- [5] N. Kai, H. Yoshida, and T. Shibata, "Pallet Pose Estimation Based on Front Face Shot," *IEEE Access*, vol. 13, pp. 37 624–37 631, 2025. [Online]. Available: <https://doi.org/10.1109/ACCESS.2025.3538045>
- [6] V.-D. Vu, D.-D. Hoang, P. X. Tan, V.-T. Nguyen, T.-U. Nguyen, N.-A. Hoang, K.-T. Phan, D.-T. Tran, D.-Q. Vu, P.-Q. Ngo, Q.-T. Duong, A.-N. Nguyen, and D.-C. Hoang, "Occlusion-Robust Pallet Pose Estimation for Warehouse Automation," *IEEE Access*, vol. 12, pp. 1927–1942, 2024. [Online]. Available: <https://shibaura.elsevierpure.com/en/publications/occlusion-robust-pallet-pose-estimation-for-warehouse-automation/>
- [7] C. Belezai, L. Reisinger, W. Pointner, and M. Murschitz, "Pallet Detection and 3D Pose Estimation via Geometric Cues Learned from Synthetic Data," in *Pattern Recognition and Artificial Intelligence (ICPRAI 2024)*, vol. 14893, 2025, pp. 281–295. [Online]. Available: https://link.springer.com/chapter/10.1007/978-981-97-8705-0_19
- [8] H. ElMoaqet, M. Rashed, and M. Bakr, "Multi-Stage Domain-Adapted 6D Pose Estimation of Warehouse Load Carriers: A Deep Convolutional Neural Network Approach," *Machines*, vol. 13, no. 12, 2025, art. no. 1126. [Online]. Available: <https://www.mdpi.com/2075-1702/13/12/1126>
- [9] B. Molter and J. Fottner, "Real-time Pallet Localization with 3D Camera Technology for Forklifts in Logistic Environments," in *IEEE International Conference on Service Operations and Logistics, and Informatics (SOLI)*, 2018, pp. 297–302. [Online]. Available: <https://portal.fis.tum.de/en/publications/real-time-pallet-localization-with-3d-camera-technology-for-forkl/>
- [10] J. Zhao, B. Li, X. Wei, H. Lu, E. Lü, and X. Zhou, "Recognition and Location Algorithm for Pallets in Warehouses Using RGB-D Sensor," *Applied Sciences*, vol. 12, no. 20, 2022, art. no. 10331. [Online]. Available: <https://www.mdpi.com/2076-3417/12/20/10331>
- [11] Y. Shao, Z. Fan, B. Zhu, J. Lu, and Y. Lang, "A Point Cloud Data-Driven Pallet Pose Estimation Method Using an Active Binocular Vision Sensor," *Sensors*, vol. 23, no. 3, 2023, art. no. 1217. [Online]. Available: <https://www.mdpi.com/1424-8220/23/3/1217>
- [12] H. Hu, C. Xiang, and C. Kong, "Study on 3D pallet recognition and localization based on a depth camera," *Journal of Mechanical Science and Technology*, vol. 39, no. 12, pp. 7753–7762, 2025. [Online]. Available: <https://link.springer.com/article/10.1007/s12206-025-1135-z>
- [13] I. S. Mohamed, A. Capitanelli, F. Mastrogianni, S. Rovetta, and R. Zaccaria, "Detection, localisation and tracking of pallets using machine learning techniques and 2D range data," *Neural Computing and Applications*, vol. 32, no. 13, pp. 8811–8828, 2020. [Online]. Available: <https://link.springer.com/article/10.1007/s00521-019-04352-0>
- [14] Y.-Y. Li, X.-H. Chen, G.-Y. Ding, S. Wang, W.-C. Xu, B.-B. Sun, and Q. Song, "Pallet detection and localization with RGB image and depth data using deep learning techniques," in *6th International Conference on Automation, Control and Robotics Engineering (CACRE)*, 2021, pp. 306–310. [Online]. Available: <https://ieeexplore.ieee.org/document/9501390/>
- [15] E. D. S. Rocha, S. F. Chevtchenko, L. F. S. Cambuim, and R. M. Macieira, "Optimized Pallet Localization Using RGB-D Camera and Deep Learning Models," in *IEEE 19th International Conference on Intelligent Computer Communication and Processing (ICCP)*, 2023, pp. 155–162. [Online]. Available: <https://researchers.westernsydney.edu.au/en/publications/optimized-pallet-localization-using-rgb-d-camera-and-deep-learnin/>
- [16] C. Mok, I. Baek, Y. S. Cho, Y. Kim, and S. B. Kim, "Pallet Recognition with Multi-Task Learning for Automated Guided Vehicles," *Applied Sciences*, vol. 11, no. 24, 2021, art. no. 11808. [Online]. Available: <https://www.mdpi.com/2076-3417/11/24/11808>
- [17] B. Wu, S. Wang, Y. Lu, Y. Yi, D. Jiang, and M. Qiao, "A New Pallet-Positioning Method Based on a Lightweight Component Segmentation Network for AGV Toward Intelligent Warehousing," *Sensors*, vol. 25, no. 7, 2025, art. no. 2333. [Online]. Available: <https://www.mdpi.com/1424-8220/25/7/2333>
- [18] D. Meng, Y. Ren, X. Yu, X. Yin, W. Wang, and J. Men, "High-Precision Positioning and Rotation Angle Estimation for a Target Pallet Based on BeiDou Navigation Satellite System and Vision," *Sensors*, vol. 24, no. 16, 2024, art. no. 5330. [Online]. Available: <https://www.mdpi.com/1424-8220/24/16/5330>
- [19] R. Iinuma, Y. Kojima, H. Onoyama, T. Fukao, S. Hattori, and Y. Nonogaki, "Pallet Handling System with an Autonomous Forklift for Outdoor Fields," *Journal of Robotics and Mechatronics*, vol. 32, no. 5, pp. 1071–1079, 2020. [Online]. Available: <https://www.fujipress.jp/jrm/rb/robot003200051071/>
- [20] R. Iinuma, Y. Hori, H. Onoyama, T. Fukao, and Y. Kubo, "Pallet Detection and Estimation for Fork Insertion with RGB-D Camera," in *IEEE International Conference on Mechatronics and Automation (ICMA)*, 2021, pp. 854–859. [Online]. Available: <https://doi.org/10.1109/ICMA52036.2021.9512641>
- [21] R. Iinuma, Y. Hori, H. Onoyama, Y. Kubo, and T. Fukao, "Robotic Forklift for Stacking Multiple Pallets with RGB-D Cameras," *Journal of Robotics and Mechatronics*, vol. 33, no. 6, pp. 1265–1273, 2021. [Online]. Available: <https://www.fujipress.jp/jrm/rb/robot003300061265/>
- [22] E. Tsiogas, I. Kleitsiotis, I. Kostavelis, A. Kargakos, D. Giakoumis, M. Bosch-Jorge, R. J. Ros, R. L. Tarazon, S. Likothanassis, and D. Tzovaras, "Pallet detection and docking strategy for autonomous pallet truck AGV operation," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2021, pp. 3444–3451. [Online]. Available: <https://merit.url.edu/en/publications/pallet-detection-and-docking-strategy-for-autonomous-pallet-truck/>
- [23] J. Ren, Y. Pan, P. Yao, Y. Hu, W. Gao, and Z. Xue, "Deep Learning-Based Intelligent Forklift Cargo Accurate Transfer System," *Sensors*, vol. 22, no. 21, 2022, art. no. 8437. [Online]. Available: <https://www.mdpi.com/1424-8220/22/21/8437>
- [24] N. Kita and T. Kato, "Approach and Fork Insertion to Target Pallet Based on Image Measurement Method," *Sensors*, vol. 26, no. 1, 2026, art. no. 154. [Online]. Available: <https://www.mdpi.com/1424-8220/26/1/154>
- [25] M. Knitt, J. Schyga, A. Adamanov, J. Hinckeldeyn, and J. Kreutzfeldt, "Estimating the Pose of a Euro Pallet with an RGB Camera based on Synthetic Training Data," *Logistics Journal: Proceedings*, 2022. [Online]. Available: <https://proc.logistics-journal.de/article/view/1038>
- [26] H. Mueller, Y. Kim, T. Gee, and M. Nejati, "Pallet Detection and Localisation From Synthetic Data," in *Australasian Conference on Robotics and Automation (ACRA)*, 2024, author preprint arXiv:2503.22965 (2025); accepted at ACRA 2024 as stated in the author version. [Online]. Available: <https://arxiv.org/abs/2503.22965>
- [27] C. Belezai, M. Zeilinger, J. Huemer, W. Pointner, S. Wimmer, and P. Zips, "Automated pallet handling via occlusion-robust recognition learned from synthetic data," in *IEEE Conference on Artificial Intelligence (CAI)*, 2023, pp. 74–75. [Online]. Available: <https://publications.ait.ac.at/en/publications/automated-pallet-handling-via-occlusion-robust-recognition-learn/>
- [28] A. Miura, H. Uchiyama, M. Yamaguchi, N. Kai, T. Shiroshima, and H. Saito, "Real-Time 6DoF Pallet Pose Estimation with Monocular Metric Depth," in *International Conference on Computer Vision Theory and Applications (VISAPP)*, 2026, pp. 149–161. [Online]. Available: <https://www.scitepress.org/PublishedPapers/2026/146268/>
- [29] Z. Zhou, Y. Lu, and L. Lv, "Pallet localization algorithm based on improved human pose estimation with transfer learning," *The Journal of Supercomputing*, vol. 81, 2025, art. no. 471. [Online]. Available: <https://doi.org/10.1007/s11227-025-06973-w>
- [30] —, "Unmanned forklift pallet positioning algorithm based on an improved human pose estimation model," *Annals of the New York Academy of Sciences*, vol. 1551, no. 1, pp. 294–311, 2025. [Online]. Available: <https://nyaspubs.onlinelibrary.wiley.com/doi/full/10.1111/nyas.70001>
- [31] T. Ye, Z. Wang, Y. Qin, Z. Gao, and Y. Wang, "A Hypergraph Computing and Knowledge-Enhanced Framework for Forklift Pallet Pose Estimation," *Annals of the New York Academy of Sciences*, vol. 1556, no. 1, 2026, art. no. e70219. [Online]. Available: <https://doi.org/10.1111/nyas.70219>
- [32] T. Park, A. A. Efros, R. Zhang, and J.-Y. Zhu, "Contrastive Learning for Unpaired Image-to-Image Translation," in *European Conference on Computer Vision (ECCV)*, 2020. [Online]. Available: https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/792_ECCV_2020_paper.php
- [33] G. Wang, F. Manhardt, J. Shao, X. Ji, N. Navab, and F. Tombari, "Self6D: Self-Supervised Monocular 6D Object Pose Estimation," in *European Conference on Computer Vision (ECCV)*, 2020. [Online]. Available: https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/500_ECCV_2020_paper.php

- [34] G. Moon, J. Y. Chang, and K. M. Lee, “PoseFix: Model-Agnostic General Human Pose Refinement Network,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 7773–7781. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2019/html/Moon_PoseFix_Model-Agnostic_General_Human_Pose_Refinement_Network_CVPR_2019_paper.html
- [35] Y. Li, G. Wang, X. Ji, Y. Xiang, and D. Fox, “DeepIM: Deep Iterative Matching for 6D Pose Estimation,” in *European Conference on Computer Vision (ECCV)*, 2018, pp. 683–698. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Yi_Li_DeepIM_Deep_Iterative_ECCV_2018_paper.html
- [36] Y. Labbé, J. Carpentier, M. Aubry, and J. Sivic, “CosyPose: Consistent multi-view multi-object 6D pose estimation,” in *European Conference on Computer Vision (ECCV)*, 2020, pp. 574–591. [Online]. Available: https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/2838_ECCV_2020_paper.php
- [37] X. Sun, B. Xiao, F. Wei, S. Liang, and Y. Wei, “Integral Human Pose Regression,” in *European Conference on Computer Vision (ECCV)*, 2018, pp. 529–545. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Xiao_Sun_Integral_Human_Pose_ECCV_2018_paper.html
- [38] M. Rad and V. Lepetit, “BB8: A Scalable, Accurate, Robust to Partial Occlusion Method for Predicting the 3D Poses of Challenging Objects Without Using Depth,” in *IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 3828–3836. [Online]. Available: https://openaccess.thecvf.com/content_iccv_2017/html/Rad_BB8_A_Scalable_ICCV_2017_paper.html
- [39] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778. [Online]. Available: <https://arxiv.org/abs/1512.03385>
- [40] B. Xiao, H. Wu, and Y. Wei, “Simple Baselines for Human Pose Estimation and Tracking,” in *European Conference on Computer Vision (ECCV)*, 2018, pp. 472–487. [Online]. Available: https://link.springer.com/chapter/10.1007/978-3-030-01231-1_29
- [41] G. Terzakis and M. Lourakis, “A Consistently Fast and Globally Optimal Solution to the Perspective-n-Point Problem,” in *European Conference on Computer Vision (ECCV)*, 2020, pp. 478–494. [Online]. Available: https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/1969_ECCV_2020_paper.php
- [42] J. Tremblay, T. To, B. Sundaralingam, Y. Xiang, D. Fox, and S. Birchfield, “Deep Object Pose Estimation for Semantic Robotic Grasping of Household Objects,” in *Conference on Robot Learning, Proceedings of Machine Learning Research*, vol. 87, 2018, pp. 306–316. [Online]. Available: <https://proceedings.mlr.press/v87/tremblay18a.html>
- [43] T. Hodan, F. Michel, E. Brachmann, W. Kehl, A. G. Buch, D. Kraft, B. Drost, J. Vidal, S. Ihrke, X. Zabulis, C. Sahin, F. Manhardt, F. Tombari, T.-K. Kim, J. Matas, and C. Rother, “BOP: Benchmark for 6D Object Pose Estimation,” in *European Conference on Computer Vision (ECCV)*, 2018. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Tomas_Hodan_PESTO_6D_Object_ECCV_2018_paper.html
- [44] G. C. Cawley and N. L. C. Talbot, “On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>
- [45] Joint Committee for Guides in Metrology, “Evaluation of measurement data — Guide to the expression of uncertainty in measurement,” JCGM, Tech. Rep. 100:2008, 2008. [Online]. Available: https://www.bipm.org/documents/20126/2071204/JCGM_100_2008_E.pdf